

# PCC170 - Projeto e Análise de Experimentos Computacionais

Marco Antonio M. Carvalho

Departamento de Computação  
Instituto de Ciências Exatas e Biológicas  
Universidade Federal de Ouro Preto



- 1 Teste de hipóteses
- 2 Teste de normalidade
  - Shapiro-Wilk normality test

## Fonte

Este material é parcialmente baseado no conteúdo de

- ▶ Alboukadel Kassambara. *Statistical tools for high-throughput analysis*. 2022. Disponível em <https://bityli.com/ixKGg>
- ▶ Chi Yau. *R tutorial: An R introduction to statistics*. 2022. Disponível em <https://bityli.com/qSzEd>

## Licença

Este material está licenciado sob a Creative Commons BY-NC-SA 4.0. Isto significa que o material pode ser compartilhado e adaptado, desde que seja atribuído o devido crédito, que o material não seja utilizado de forma comercial e que o material resultante seja distribuído de acordo com a mesma licença.

## Introdução

Existem 5 etapas principais no teste de hipóteses:

- ▶ Declare sua hipótese de pesquisa como uma hipótese nula ( $H_o$ ) e uma hipótese alternativa ( $H_a$ ).
- ▶ Colete dados de uma maneira projetada para testar a hipótese.
- ▶ Realize um teste estatístico apropriado.
- ▶ Decida se rejeita ou deixa de rejeitar sua hipótese nula.
- ▶ Apresente os resultados em sua seção de resultados e discussão.

## Hipóteses

A **hipótese nula** ( $H_o$ ) é uma previsão de nenhuma relação entre as variáveis.

A **hipótese alternativa** ( $H_a$ ) geralmente é nossa hipótese inicial que prevê uma relação entre as variáveis.

## Hipóteses

Por exemplo, queremos testar se existe uma relação entre sexo e altura.

Com base em nosso conhecimento da fisiologia humana, formulamos uma hipótese de que **os homens são, em média, mais altos que as mulheres.**

Para testar essa hipótese, a reafirmamos como:

- ▶  $H_o$ : Os homens não são, em média, mais altos que as mulheres.
- ▶  $H_a$ : Os homens são, em média, mais altos que as mulheres.

## Coleta de dados

Para que um teste estatístico seja válido, é importante realizar a amostragem e coletar dados de uma maneira projetada para testar a hipótese.

Se os dados não forem representativos, não poderemos fazer inferências estatísticas sobre a população em que estamos interessados.

Para nosso exemplo, a amostra deve ter uma proporção igual de homens e mulheres e abranger uma variedade de classes socioeconômicas e quaisquer outras variáveis de controle que possam influenciar a altura média.

# Teste de hipóteses

## Realização de testes estatísticos

Há uma variedade de testes estatísticos disponíveis, mas todos eles são baseados em duas comparações

**Variância dentro do grupo:** quão espalhados os dados estão dentro de uma categoria.

**Variância entre grupos:** quão diferentes as categorias são umas das outras.



## Realização de testes estatísticos

Se a variação entre os grupos for grande o suficiente para que haja pouca ou nenhuma sobreposição entre os grupos, seu teste estatístico refletirá isso mostrando um *p-value* baixo.

Isso significa que é improvável que as diferenças entre esses grupos tenham surgido por acaso.

## Realização de testes estatísticos

Alternativamente, se houver alta variância dentro do grupo e baixa variância entre grupos, seu teste estatístico refletirá isso com um *p-value* alto.

Isso significa que é provável que qualquer diferença medida entre os grupos seja devido ao acaso.

# Teste de hipóteses

## Realização de testes estatísticos

Com base no tipo de dados coletados, realizamos um *t-test* (ou *teste t*) unicaudal para testar se os homens são de fato mais altos que as mulheres.

Este teste nos dá:

- ▶ Uma estimativa da diferença de altura média entre os dois grupos.
- ▶ Um *p-value* mostrando a probabilidade de ocorrência dessa diferença se a hipótese nula de nenhuma diferença for verdadeira.

O *teste t* mostra uma altura média de 175,4 cm para homens e uma altura média de 161,7 cm para mulheres, com uma estimativa da diferença real variando de 10,2 cm ao infinito.

O *p-value* é 0,002.

## Análise do resultado

Com base no resultado do teste estatístico, decidimos se rejeitamos ou não a hipótese nula.

Geralmente, o nível de significância predeterminado para rejeitar a hipótese nula é de 0,05, i.e., quando houver menos de 5% de chance de ocorrerem esses resultados se a hipótese nula for verdadeira.

Em alguns casos, os pesquisadores escolhem um nível de significância mais conservador, como 0,01 (1%). Isso minimiza o risco de rejeitar incorretamente a hipótese nula (**erro tipo I**).

## Análise do resultado

Em nossa análise da diferença na altura média entre homens e mulheres, descobrimos que o *p-value* de 0,002 está abaixo do ponto de corte de 0,05. Portanto, decidimos por rejeitar a hipótese nula de que os homens não são, em média, mais altos que as mulheres.

## Reportando os resultados

Na linguagem formal do teste de hipóteses, falamos em rejeitar ou deixar de rejeitar a hipótese nula.

De outra forma, voltamos à nossa hipótese alternativa, a de que os homens são, em média, mais altos que as mulheres, e afirmamos se o resultado do nosso teste foi consistente ou inconsistente com ela.

Se a hipótese nula foi rejeitada, esse resultado é interpretado como consistente com a hipótese alternativa.

## Reportando os resultados

“Encontrou-se uma diferença de estatura média entre homens e mulheres de 13,7 cm, com *p-value* de 0,002, consistente com a hipótese de que há diferença de estatura entre homens e mulheres.”

## Reportando os resultados

Note não dizemos que rejeitamos ou deixamos de rejeitar a **hipótese alternativa**.

Isso ocorre porque o teste de hipóteses não é projetado para provar ou refutar nada, apenas para testar se um padrão que medimos pode ter surgido de forma espúria ou por acaso.



## Reportando os resultados

Se rejeitarmos a hipótese nula com base em nossa pesquisa, i.e., descobrirmos que é improvável que o padrão tenha surgido por acaso, podemos dizer que nosso teste **dá suporte à nossa hipótese**.

Entretanto, se o padrão não passar em nossa regra de decisão, o que significa que poderia ter surgido por acaso, então dizemos que o teste é **inconsistente com nossa hipótese**.

## Perguntas de pesquisa e testes estatísticos

As perguntas de pesquisa mais populares incluem:

- 1 Se duas variáveis ( $n = 2$ ) estão correlacionadas.
- 2 Se múltiplas variáveis ( $n > 2$ ) estão correlacionadas.
- 3 Se dois grupos ( $n = 2$ ) de amostras diferem um do outro.
- 4 Se vários grupos ( $n \geq 2$ ) de amostras diferem uns dos outros.
- 5 Se a variabilidade de duas amostras difere.

Particularmente, as questões 3 e 4 se relacionam à comparação de resultados gerados por dois métodos (3) ou por vários métodos (4).

## Requisitos de testes estatísticos

Muitos dos procedimentos estatísticos assumem algumas características específicas sobre os dados.

Geralmente estes procedimentos assumem que:

- ▶ Os dados são normalmente distribuídos.
- ▶ As variâncias dos grupos a serem comparados são homogêneas.

Essas suposições devem ser levadas a sério para extrair interpretações e conclusões confiáveis da pesquisa.

## Como testar a normalidade dos dados?

Com tamanhos de amostra suficientemente grandes, a violação da suposição de normalidade não deve causar grandes problemas.

O **teorema central do limite** nos diz que não importa qual distribuição os dados tenham, a distribuição amostral tende a ser normal se a amostra for grande o suficiente ( $n > 30$ ).

No entanto, para ser consistente, podemos usar o teste de Shapiro-Wilk comparando a distribuição da amostra com uma normal para verificar se os dados mostram ou não um desvio grave da normalidade.

## Testar ou não testar a normalidade?

A normalidade dos dados e as demais suposições feitas pelos testes de hipóteses devem ser testados previamente.

Em algumas áreas, os dados normalmente distribuídos são a exceção e não a regra.

Em tais situações, o uso de métodos paramétricos é desencorajado e testes não paramétricos são recomendados.

# Teste de normalidade

## Depois do teste de normalidade

Caso os dados sejam distribuídos normalmente, utiliza-se um teste **paramétrico** para comparar os dados de dois algoritmos.

Caso contrário, a distribuição não é normal e um teste **não-paramétrico** deve ser utilizado para comparar os dados de dois algoritmos.

# Shapiro-Wilk normality test

## Introdução

O *Shapiro-Wilk* é um teste de normalidade para populações de tamanho até 30 (ou 50, para alguns autores).

Este método é amplamente recomendado e fornece melhor potência do que o teste de *Kolmogorov-Smirnov*.

A hipótese nula é a de que a distribuição amostral é normal.

# Shapiro-Wilk normality test

## Como executar o teste

No *R*, crie uma série de dados *MetodoA*, atribua os valores e execute o teste.

```
1 > MetodoA <- c(1.0, 2.0, 3.0, 4.0)
2 > shapiro.test(MetodoA)
```



# Shapiro-Wilk normality test

Shapiro-Wilk normality test

data: MetodoA

W = 0.99291, p-value = 0.9719


## Análise

São retornados um valor  $W$  e o  $p$ -value.

Se o  $p$ -value for menor do que um valor crítico dado pelo nível de significância  $\alpha$  (normalmente 0,05), então o pressuposto de normalidade é rejeitado no nível de significância  $\alpha$ .

Em outras palavras, há evidência de que os dados testados não pertencem a uma população normalmente distribuída.

Embora seja reportado, o valor de  $W$  não é interpretado diretamente.

A statistical analysis was performed to compare the two methods. The Shapiro–Wilk normality test ([Shapiro & Wilk, 1965](#)) confirmed the null hypothesis that the results compared from BRKGA ( $W = 0.88405$ ,  $p\text{-value} = 0.09879$ ) and  $M_1$  ( $W = 0.89268$ ,  $p\text{-value} = 0.1276$ ) could be modeled according to a normal distribution, with a confidence interval of 95%.  ([Student, 1008](#)) was applied to verify whether there is a significant

Fonte: Soares, Leonardo Cabral R., and Marco Antonio M. Carvalho. *Biased random-key genetic algorithm for scheduling identical parallel machines with tooling constraints*. European Journal of Operational Research 285.3 (2020): 955-964.

The Shapiro–Wilk normality test (Shapiro & Wilk, 1965) was applied separately for the Grid and HB sets for each algorithm, which rejected the null hypothesis that the results of ALNS (p-value equal to  $4.989 \cdot 10^{-5}$  and p-value less than  $2.2 \cdot 10^{-16}$ ) and VFS (p-value equal to  $4.873 \cdot 10^{-6}$  and p-value less than  $2.2 \cdot 10^{-16}$ ) could be modeled according to a normal distribution. Subsequently, given that the populations are

Fonte: Santos, Vinícius Gandra Martins, and Marco Antonio Moreira de Carvalho. *Tailored heuristics in adaptive large neighborhood search applied to the cutwidth minimization problem*. European Journal of Operational Research 289.3 (2021): 1056-1066.

# Dúvidas?

